

Relazione finale, progetto “Hotel Reviews”

di Roberto Zagonel

1.Introduzione

Questo documento vuole raggruppare tutti i procedimenti e ragionamenti dietro la realizzazione del progetto “Hotel Reviews”, che rappresenta un’ampia analisi di una banca dati fornita da Booking.com di clienti reali, nel periodo 2015-2017, per identificare relazioni e legami tra le recensioni e i suoi attributi, correlazioni tra variabili e conclusioni utili per il settore turistico. Si tratta di una raccolta di circa 515000 recensioni di 1494 hotel presenti in Europa, e si ha a disposizione informazioni come indirizzo, numero di recensioni, nazionalità delle persone che recensiscono, la data della recensione e così via.

Premessa

In questo report si farà continuo riferimento ai risultati e grafici ottenuti, i quali sono presenti separatamente all’interno della Repository di Github ove è stato possibile ottenere e leggere questa relazione. Non verranno mostrati qui, ma nel momento della trattazione si farà diretto riferimento al file specifico, così da poter seguire agilmente il discorso.

2.Procedimento

Ora verranno illustrati i passaggi principali di questo progetto, assieme ai risultati ottenuti di pari passo.

Pulizia

La banca dati si è ottenuta scaricandola da un link fornito a priori, probabilmente proveniente da Kaggle, sito famoso per la possibilità di trovare svariati database di tutti i tipi.

A questo punto utilizzando Pandas tuttavia, dopo una breve visione e analisi delle dimensioni, è evidente come sia necessario trattare la banca dati per renderla pulita e agevole dal punto di vista analitico. Quindi si vuole procedere inizialmente con la cancellazione di righe “inutili” (ossia mancanti di informazioni cruciali). Si nota però che gli unici dati mancanti sono relativi a circa 3000 latitudini e longitudini, e con maggiore precisione tutte legate a un particolare hotel viennese. Dunque si è deciso semplicemente di sostituire quei dati mancanti con valori nulli, poiché il ragionamento dietro alla non cancellazione è che l’informazione di latitudine e longitudine risulta superflua quando si ha a disposizione nome e indirizzo dello specifico hotel. A seguire sono stati rilevati circa 500 duplicati, prontamente eliminati.

In questo modo si è arrivati all’ottenimento di un primo database pulito, con 515212 righe e 17 colonne distinte, racchiuso nel file **DFHotel_Reviews_Cleaned.py**.

Inoltre per ragioni di comodità (cioè per facilitare la creazione del database in MySQL, piccola anticipazione) è stato creato anche il file **DFHotel_Reviews_Definitive.py**, nel quale sono presenti colonne aggiuntive che fanno riferimento a nuovi parametri creati per le relazioni tra tabelle, come id_hotel o id_review.

MySQL

Il passo successivo è stato quello della creazione del database sulla piattaforma MySQL.

Nel file **databaseSQL.Hotel_Reviews.txt**, sono presenti i comandi specifici per la creazione di suddetto database. In breve, sono state realizzate 4 tabelle principali: Hotel, Hotel_Stats, Reviews e Reviewers. Si è cercato di rispettare la struttura originale del database, a cui sono stati aggiunti certi attributi per meglio catalogare le informazioni (es. da data completa a mese e anno) oppure per creare i legami tra tabelle attraverso le chiavi esterne (es. id_hotel). Essenzialmente a Hotels sono stati attribuiti nome, indirizzo, latitudine e longitudine. A Hotel si è legato Hotel_Stats che racchiude informazioni qualitative, cioè punteggio medio, numero totale di recensioni ricevute e punteggio totale. A Hotel è stato legato anche Reviews, che comprende la data in cui è stata realizzata la recensione e la data in cui è stata pubblicata, il commento positivo e negativo distinti, con i loro conteggi di parole, il punteggio e aggettivi per meglio identificare il tipo di pernottamento. Infine il Reviews è legato a Reviewers, che possiede la nazionalità delle persone che recensisce, il numero totale di recensioni scritte e il conteggio di giorni dall’ultima volta in cui ne ha scritta una. Come chiavi esterne c’è id_stats

che lega Hotels e Hotel_Stats; id_hotel e id_review tra Hotels e Reviews; infine id_reviewer tra Reviews e Reviewers.

Successivamente queste tabelle sono state popolate dall'importazione di file CSV trattati anticipatamente. In questo modo è terminata la prima fase.

Query SQL e risultati

Per prima cosa, dopo un breve controllo, si vede che le dimensioni originarie del database sono state rispettate; risultano sempre 515212 recensioni per 1494 hotel.

A questo punto sono state realizzate delle query per ottenere una serie di risultati utili per l'analisi richiesta. Qui è riportata la lista delle richieste:

1. Recensioni nel Tempo

- Andamento recensioni mese e anno
- Hotel con picco recensioni

2. Nazionalità Recensori

- Top 10 nazionalità per numero recensioni e score medio
- % contributo top nazionalità al totale recensioni
- Confronto score medio UK vs altri

3. Hotel e Performance

- Hotel con maggior Average_Score e numero recensioni
- Analisi gap tra Reviewer Score e Average Score

4. Geografia

- Distribuzione recensioni per città
- Score medio per nazione, top città

5. Lunghezza Recensioni

- Distribuzione Review_Length per categoria score
- Correlazione lunghezza recensione vs Reviewer_Score

Il codice delle query qui realizzate si trova in **QuerySQL_Hotel_Reviews.txt**; inoltre sono presenti screenshot dei risultati ottenuti (verranno discussi in questa relazione di pari passo) nella cartella **Raccolta screen per HotelReviews**.

In “Andamento recensioni mese e anno” si è sommato il numero totale delle recensioni e lo si è suddiviso su base temporale, prima raggruppato in mesi e poi in anni. Viene dimostrato come nei periodi tardo primaverili e soprattutto estivi si presentino i massimi di recensioni ricevute, e come l’anno 2016 totalizzi più degli altri poiché è l’unica annata contata completamente: le altre 2 sono troncate.

In “Hotel con picco recensioni” si è raggruppato il numero totale di recensioni con i nomi degli hotel, i cui primi 3, che sono “Britannia International”, “Strand Palace” e “Park Plaza” hanno superato la soglia delle 4000 unità. Serve notare che prendendo le tutte le recensioni e dividerle per il numero totale di hotel si ottiene una media di circa 350 recensioni per hotel.

In “Top 10 nazionalità per numero recensioni e score medio” si è contato il numero totale di recensori (ad ogni persona corrisponde una recensione distinta), suddivisi dalle 10 nazionalità maggiormente presenti; infine si è calcolata la media dei punteggi delle nazioni. Si nota come quasi la metà della totalità delle recensioni scritte provengono da persone inglesi dell’Inghilterra, e in generale la maggior parte delle persone appartiene alla sfera anglofona. Inoltre la media dei punteggi è particolarmente elevata, si assesta sopra l’8, se si considera che la scala parte da 0 e va a 10. Da aggiungere che nei paesi non occidentali, la media non supera l’8.

In “% contributo top nazionalità al totale recensioni” si sono contate le recensioni, si sono suddivise per paesi di provenienza dei recensori e si è realizzata la percentuale. Si ha un’ulteriore conferma della maggioranza anglofona. Se si somma la presenza di UK, USA e Australia, la percentuale dei recensori ammonta a 58,5%, quasi due terzi del totale.

In “Confronto score medio UK vs altri” si sono suddivisi i recensori in inglesi e non inglesi, a cui si è calcolata la media dei punteggi. Sembrerebbe che gli inglesi siano più gentili oppure più soddisfatti per le loro esperienze in hotel rispetto ai non inglesi.

In “Hotel con maggior Average_Score e numero recensioni” si mettono in relazione hotel, punteggi medi e recensioni totali. Ordinando per media, si nota come i valori siano molto elevati, sopra il 9,5 per i primi 15, tuttavia le recensioni non superano le migliaia. Ordinando

per recensioni invece i primi 3 hotel superano i 10000 valori con medie sopra l'8. Quindi si intravede quantomeno un andamento inversamente proporzionale non indifferente tra media e recensioni totali, come se un minor numero di recensioni rendano gli hotel più suscettibili a sbalzi di punteggio.

In "Analisi gap tra Reviewer Score e Average Score" il gap rappresenta la differenza tra il punteggio medio dell'hotel e i singoli punteggi delle recensioni. Si vede come esistano salti importanti nei primi 20 risultati, ma contando oltre 1400 hotel, in media il gap è limitato. Probabilmente questi dati sono ingigantiti dal fatto che per qualsivoglia motivazione i pernottamenti in questi hotel sono stati pochi e le esperienze non rappresentative, poiché è da sottolineare come i punteggi di questi hotel siano quasi stellari.

In "Distribuzione recensioni per città" si è estratta la città e nazione dalla stringa degli indirizzi (poiché United Kingdom è l'unica nazione formata da 2 parole, è stata sostituita da UK) e si son contate le recensioni registrate per città.

Senza ulteriori specificazioni, è evidente come gli hotel si suddividano in 6 principali città europee, che sono Milano, Vienna, Amsterdam, Barcellona e Parigi, l'ultima è Londra, nella quale però ci sono moltissimi hotel sparsi nei suoi vari quartieri. In conclusione, con informazioni più precise si sarebbero potute distinguere più città/località, ma anche per semplicità si è deciso di distinguerle in questo modo. Nuovamente si vede come la città londinese rappresenti la grande fetta delle recensioni superando la metà.

In "Score medio per nazione, top città" con la stessa estrazione di città e nazione si vuole confrontare la media delle recensioni, la quale è elevata e non si abbassa sotto l'8. La vincitrice è Vienna, ma tra di loro i risultati non si discostano molto.

In "Distribuzione Review_Length per categoria score" si sono creati 4 gruppi di punteggio: ottimo, buono, sufficiente e scarso. Lo scopo è quello di misurare la lunghezza delle singole recensioni in generale (somma tra quelle positive e negative) e inserirla nelle categorie.

Qui è palese come ci sia una vera e propria correlazione tra la lunghezza delle recensioni e il basso punteggio riscosso. L'interpretazione è che chi rimanga soddisfatto abbia da esprimere solamente poche parole ma di ringraziamento; quando invece lamenta di un'esperienza negativa abbia molta più foga nell'esprimere le proprie problematiche affrontate.

In “Correlazione lunghezza recensione vs Reviewer_Score” diversamente da prima si è raggruppato la lunghezza della recensione, in lunga, media e breve grandezza, messa in relazione con il punteggio. Come nella query precedente, viene confermato il fatto che un’esperienza peggiore comporti una recensione più lunga e dettagliata.

Python con Pandas

Il capitolo seguente riguarda Python. Nonostante sia stato utilizzato fin dal principio con Pandas per la pulizia e creazione del database pulito, da cui è partita la creazione delle tabelle su SQL e le successive query, solamente da questo punto viene utilizzato non per riarrangiare i dati, ma per trarne delle conclusioni tramite operazioni e grafici, da altre librerie come numpy, statistics e, a termine di questa parte, matplotlib. Tutte le sezioni di comandi adottati sono riportati nel file **Hotel_Reviews_Matplotlib.ipynb**.

Analisi Pandas e risultati

Dopo aver caricato il database, è richiesto di riprodurre le principali analisi realizzate precedentemente tramite SQL, ossia “group by mensile”, “ranking nazionalità” e “distribuzione città”, e in seguito di confrontare i rispettivi risultati.

In “group by mensile” si vuole racchiudere la conta del numero complessivo di recensioni e vedere come è distribuita nell’arco temporale dei dati raccolti; si sono sommate dunque le recensioni totali suddividendole in mesi e anni. Nulla cambia da ciò che è stato ottenuto da SQL: i dati non coincidono con inizio del 2015 e fine del 2017, quindi nell’anno 2016 si ottengono i valori massimi. Inoltre si vede come il totale dei periodi estivi, anche primaverili, non venga superato dalle altre stagioni.

In “ranking nazionalità” si vuole distinguere le recensioni per i più ricorrenti paesi di provenienza delle persone che le hanno scritte e vederne l’andamento rispetto al numero totale di recensioni, la percentuale di questo sul totale e il punteggio medio. Nuovamente i risultati coincidono con quelli di SQL: quasi due terzi del totale provengono da paesi

anglofoni, con medie di punteggio sull'8,5. Gli unici paesi non occidentali, Emirati Arabi Uniti e Arabia Saudita, non arrivano all'8 di media.

In “distribuzione città” viene richiesta una semplice distribuzione tra il numero totale di recensioni e le città associate. Si noti che per ottenere la città (e nazione) è stato necessario estrarre le ultime parole dalla stringa dell'indirizzo, in cui inoltre è stato sostituito al “United Kingdom” (2 parole) la singola parola “UK” per leggibilità e adattamento dei valori testo. La conseguenza di ciò è legata al fatto che oggettivamente sono presenti solamente 6 città in totale, il cui numero sarebbe potuto aumentare se si avesse voluto considerare non la città intera, bensì i quartieri che la consistono. Infatti da notare come a Londra ci siano molti quartieri (es. Chelsea, Westminster, Greenwich, Fullham ecc.). Quindi, i risultati corrispondono a quelli di SQL: più della metà delle recensioni sono scritte su Londra, Milano qui è la perdente.

Grafici Matplotlib e risultati

L'ultimo tipo di analisi eseguita è la creazione di grafici specifici tramite la libreria Matplotlib, che riesce ad estrarre importanti relazioni dal database e improntarle su immagini chiare e facilmente interpretabili.

I grafici richiesti in questa sono i seguenti:

1. Line plot recensioni/mese e recensioni/anno
2. Bar chart top 10 nazionalità per recensioni
3. Bar chart top 10 città per numero recensioni
4. Box plot distribuzione Reviewer Score per nazionalità top 3
5. Histogram Review Length per categoria score
6. Scatter plot Review Length vs Reviewer Score (colore per nazionalità)
7. Bar chart score medio per top 10 città
8. Heatmap correlazioni numeriche (score, word counts, days since review)

Per “Line plot recensioni/mese e recensioni/anno” sono stati realizzati 2 grafici a linea, i quali identificano rispettivamente l’andamento delle recensioni totali per mese prima, e l’andamento delle recensioni totali per anno. Si ricordi che questa analisi è già stata completata con SQL e Pandas. Si vede come tendenzialmente le recensioni per mese restino sui 20000, con un picco nell’estate 2016. Inoltre come detto in precedenza, il totale del 2016 supera quello degli altri anni in quanto è l’unica annata ad essere interamente trascorsa.

Per “Bar chart top 10 nazionalità per recensioni” è stato realizzato un grafico a colonne che riunisce le prime 10 nazioni di provenienza dei recensori per numero complessivo di recensioni, analisi già affrontata in precedenza. Qui è chiaro come l’Inghilterra sormonti ogni altra nazione presente.

Per “Bar chart top 10 città per numero recensioni”, è richiesto un nuovo grafico a colonne che riunisce invece le prime 10 città (sappiamo già che sono in totale 6) per capire quante recensioni collezionano. Un’altra volta ancora è l’Inghilterra con la sua capitale Londra che vince con ampio margine.

Per “Box plot distribuzione Reviewer Score per nazionalità top 3” si vuole misurare statisticamente la distribuzione delle mediane e dei quartili dei punteggi delle recensioni, raggruppata per le prime 3 nazioni di provenienza dei recensori. Si intuisce che il box dell’Inghilterra è molto più esteso da ambo le parti rispetto agli altri due per la maggiore quantità di dati presenti. In generale, i punteggi sono ristretti in votazioni molto alte, trovandosi molto vicini alla cima del grafico. Le mediane si trovano in altezza superiore rispetto alle medie, infatti si trovano punteggi molto negativi al di fuori della scatola. Tuttavia l’aspetto cruciale è come la maggior parte delle recensioni sia collocata in uno spazio ristretto. Infine sembra che gli americani siano restati molto più impressionati dall’esperienza rispetto agli altri anglofoni.

Per “Histogram Review Length per categoria score” è stato realizzato un istogramma le cui colonne corrispondono alle 3 categorie di lunghezza della recensione (comprendente la parte positiva e la parte negativa sommate assieme): breve, media e grande; i valori delle ordinate invece sono le recensioni totali per categoria. Si vede come le recensioni più brevi sono molto più popolate rispetto a recensioni di lunghezza più estesa.

Per “6. Scatter plot Review Length vs Reviewer Score (colore per nazionalità)” si è creato un grafico scatter in cui sono raccolte sempre la lunghezza assoluta delle recensioni, messe in relazione con il punteggio che esprimono. Tutto questo poi è suddiviso per i paesi di

provenienza dei recensori. In questo modo è possibile confrontare la lunghezza delle recensioni, il suo punteggio e dividerlo per cittadinanza dei recensori. Come detto prima si nota come la maggior parte dei pallini si trovino a lunghezze inferiori, in cui mescolati i colori si vedono soprattutto tonalità di viola. Progressivamente con l'aumento della lunghezza si trovano soprattutto pallini blu degli inglesi, i quali sono i più numerosi. Infine in generale sono presenti più pallini a punteggi maggiori.

Per “Bar chart score medio per top 10 città” attraverso un grafico a colonne si vuole rapportare il punteggio medio totalizzato per città. La media abbiamo visto già essere di valore elevato, sopra l'8; però oggettivamente i valori si discostano pressoché di nulla tra città diverse. Londra qui è la città con punteggio medio più basso; al contrario la vincitrice è Vienna, con un valore di circa 0.3 maggiore.

Per “Heatmap correlazioni numeriche (score, word counts, days since review)” è stato richiesto un nuovo grafico scatter per mettere il confronto punteggio, lunghezza totale delle recensioni e il tempo trascorso tra la compilazione delle recensioni e la loro effettiva registrazione del database. Si è deciso di relazionare lunghezza e tempo trascorso, raggruppando poi il punteggio. Di primo impatto è evidente come a una maggiore lunghezza di recensione, tralasciando il tempo trascorso, vengano registrati punteggi inferiori. Infine sembra che la maggior parte delle recensioni vengano registrate nel breve periodo; però allo stesso tempo non sono poche le recensioni compilate mesi, pure anni, addietro.

Conclusioni

A seguito di tutte queste analisi, si possono trarre importanti considerazioni. Per cominciare, si possono semplificare 2 aspetti: il primo, le città e le loro recensioni collezionate si possono dividere in 2 parti Londra e le altre 5 città europee; il secondo, si possono dividere nuovamente in 2 parti i recensori inglesi e i recensori globali.

Un'importante relazione che è apparsa più volte è come la qualità dell'esperienza (e quindi il punteggio) sia inversamente proporzionale alla lunghezza della recensione. Infatti sembra come se le persone avessero molto più da esprimere quando abbiano incontrato più problematiche da lamentare; invece se l'esperienza sia risultata molto positiva, sembra che fossero necessarie poche parole di ringraziamento.

Però in generale sono state collezionate molte più recensioni di media-corta lunghezza, il che comporta come nelle medie dei punteggi siano risultati comunque valori piuttosto elevati.

In ogni caso sono stati trovati alcuni hotel in cui i punteggi percepiti e quelli effettivamente attribuiti dai clienti differivano enormemente. Tuttavia, considerando che questi hotel si contano in poche decine, e per le altre centinaia di hotel il gap è irrilevante, si può intuire come molto probabilmente per decine di motivi tali recensioni non rappresentino nella totalità la reale esperienza che potrebbe avvenire. Inoltre sono presenti degli hotel i cui punteggi sono stellari; in contrasto le recensioni registrate sono sulle poche centinaia. Quindi sulla scala di mezzo milione di recensioni e 1500 hotel si può affermare che statisticamente l'effettiva qualità dei dati raccolti è presente.

In conclusione, da queste analisi emerge come i dati siano piuttosto polarizzati nei confronti di Londra e dei suoi abitanti. In ogni caso i clienti in quei 2 anni negli hotel d'Europa, dislocati in 6 importanti capitali, abbiano vissuto esperienze oggettivamente molto buone; gli stessi clienti poi provengono soprattutto dal mondo anglofono, in cui sembra che i loro abitanti restino maggiormente soddisfatti dalle esperienze in hotel europei.